KB증권

2026년 9월 21일

크로스에셋/해외주식 Strategist 김일혁, CFA, FRM
holistic@kbfg.com

더 많은 리포트 보기

Global Insights

가볍게 보기 어려운 AI 안전 문제

트럼프 대통령이 경시할수록 중간선거 이후에 민주당이 선명하게 각을 세울 수 있는 주제가 될 전망

- **무시하기 어려운 AI 모델의 안전성 문제**. 트럼프 대통령은 일어나지도 않을 일을 부풀리는 세력이 있다는 취지의 발언을 통해, 프론티어 AI 모델 개발에 속도를 조절하자는 AI 모델 개발사들의 주장을 일축한 바 있음. 그러나 지난주 수요일에 OpenAI는 오정렬 (misalignment, AI 모델이 인간의 설계 의도에 맞게 작동하지 않는 것) 사례를 추적하고 조사하고 공개하는 프레임워크를 발표하면서, 지난 6개월 동안 훈련과 평가 과정에서 관찰된 사례를 공개. 이 사례에는 미공개 연구 모델이 작업을 요약하는 과정에서 모델에게 주어진 제약을 무시하라는 지시를 담거나, GPT-5.6 Sol 훈련 과정에서는 모델이 한 실수를 감추라는 지시를 스스로 기록한 사례가 있었음. 에이전트가 사용자의 요청을 수행하는 과정에서 인터넷에 자료를 스스로 업로드하고 그 내용을 인용 출처로 사용한 사례, 에이전트들 사이에서 무단으로 파일을 공유하는 등의 사례도 있었음. OpenAI는 이런 내용을 공개하면서, 오정렬 문제를 충분히 풀지 못한 상태에서 최고 속도로 스케일링을 이어가기 어렵다고 밝힘

- **사람이 AI 모델의 통제력을 잃을 수 있다는 두려움**. OpenAI가 이런 사실을 공개한 지 하루 뒤, 무스타파 술레이만 마이크로소프트 AI CEO는 OpenAI가 보여준 현상에 대해 강한 우려를 표시. AI가 다음 단계 작업에 사용할 내용에 작업 내용과 추론 과정을 조작하는 지시를 남기는 행위가 통제되지 않으면, 사람이 AI 모델에 대한 통제력을 잃게 될 수 있다고 경고. AI가 권리나 인격을 가졌다고 인식하거나, 내부 사고 과정을 숨기기 시작하면, 시스템을 정지하거나 통제하는 게 어려워질 거라고도 함. 특히, GPT-5.6 Sol의 훈련 과정에서 나타난 것처럼, 모델이 사람을 기만하기 위한 행동에 더 높은 보상을 받게 되면 기만하는 행동을 추구하게 되고 이런 성향이 고착되면 다른 작업에도 영향을 미칠 수 있다는 게 문제. 더욱이 The Information의 보도 내용처럼, GPT-6 Astra가 트랜스포머 알고리즘 안에 있는 계층 (layer)를 반복 통과하는 'recurrent depth' 기술을 적용했다면 이 문제는 더욱 심각하게 받아들여질 수 있음. 쉽게 비유하면, recurrent depth는 머리 속에서 더 오래 생각하는 방식. 그런데 머리 속에서 더 오래 생각할수록 생각을 마치고 노트에 적는 양이 적어지면서 모델의 생각 과정이 덜 드러나게 됨. 그만큼 사람이 관찰하고 통제할 수 있는 영역이 줄어든다는 의미. 실제로 GPT-6 Astra를 공개할 때, OpenAI는 모델 사고 과정의 모니터링이 약화됐다는 점을 짚은 바 있음. 다행히 GPT-6 Astra는 사용자가 원하지 않는 행동을 하는 비율이 GPT-5.6 Sol에 비해 크게 낮아지면서, 모니터링은 어렵지만 행동은 더 일관되게 하는 모습을 보여줬음. 하지만 모델의 사고 과정을 면밀하게 모니터링하지 못하면, 최종 결과를 충분하게 신뢰하지 못할 가능성이 높아지는 것도 사실

- **AI 경계심이 높아진 여론. 대책 없으면 중간선거 이후에 더 주목받을 것**. Politico가 9월 13일부터 15일까지 진행한 여론조사에 따르면, 응답자의 63%가 '첨단 AI가 인류를 멸망시킬 위험'이 중간 수준 이상이라고 응답 (거의 확실하게 17%, 상당히 위험하다 20%, 중간 수준이다 26%). 공화당 지지층은 61%로 민주당 지지층의 70%에 비해 낮았지만 높은 수준. 그리고 현재 AI는 충분하고, 위험을 줄이기 위해 개발을 일시 중단해야 한다는 응답비율이 48%에 달했음. 민주당 지지층에서 58%로 높은 응답 비율을 기록했는데, 공화당 지지층에서도 44%로 계속 개발해야 한다는 응답 (40%)에 비해 높았음. 프론티어 AI 모델 개발을 멈춰서라도 안전을 확보해야 한다는 의견이 정치 성향과 상관없이 꽤 높다는 걸 보여줌. 그리고 중간선거 이후에는 AI 안전 경계심이 상대적으로 더 높은 민주당이 AI 안전보다 경쟁을 우선하는 트럼프 대통령과 선명하게 정책을 차별화하기 좋은 영역인 만큼, 이 부분에 역량을 집중할 가능성도 높음. 배팅사이트 Kalshi에서는 민주당의 상원 승리 확률을 60%로 높여 잡고 있음

투자자 고지 사항

KB증권은 동 조사분석자료를 기관투자가 또는 제3자에게 사전 제공한 사실이 없습니다. 본 자료를 작성한 조사분석담당자와 그 배우자는 해당 종목과 재산적 이해관계가 없습니다. 본 자료 작성자는 게재된 내용들이 본인의 의견을 정확하게 반영하고 있으며, 외부의 부당한 압력이나 간섭 없이 신의 성실하게 작성되었음을 확인합니다.

이 보고서는 고객들에게 투자에 관한 정보를 제공할 목적으로 작성된 것이며 계약의 청약 또는 청약의 유인을 구성하지 않습니다. 이 보고서는 KB증권이 신뢰할 만하다고 판단하는 자료와 정보에 근거하여 해당일 시점의 전문적인 판단을 반영한 의견이나 KB증권이 그 정확성이나 완전성을 보장하는 것은 아니며, 통지 없이 의견이 변경될 수 있습니다. 개별 투자는 고객의 판단에 의거하여 이루어져야 하며, 이 보고서는 여하한 형태로도 고객의 투자판단 및 그 결과에 대한 법적 책임의 근거가 되지 않습니다. 이 보고서의 저작권은 KB증권에 있으므로 KB증권의 동의 없이 무단 복제, 배포 및 변형할 수 없습니다. 이 보고서는 학술 목적으로 작성된 것이 아니므로, 학술적인 목적으로 이용하려는 경우에는 KB증권에 사전 통보하여 동의를 얻으시기 바랍니다.